

SunSaver ETL

Plataforma de Inteligencia Fotovoltaica

Transformando datos brutos de generacion solar y meteorologia en decisiones energeticas respaldadas por datos para instalaciones industriales.

Tipo	Referencia Tecnica - Descripcion Completa del Pipeline
Version	1.0
Dominio	Gestion Energetica Industrial / Ingenieria de Datos
Stack	Python 3.11+ · pvlib · SQLite · pandas · SQLAlchemy
Arquitectura	ETL Medallion (Bronce -> Plata -> Oro)

1. Resumen Ejecutivo

SunSaver ETL es un pipeline de datos de calidad productiva diseñado para resolver un problema concreto y costoso en la gestion energetica industrial: la ausencia de una vision unificada, fundamentada en fisica y en tiempo real, de la generacion solar, el consumo energetico y los precios del mercado electrico para instalaciones con paneles fotovoltaicos.

Las instalaciones industriales con sistemas FV operan habitualmente sin saber si sus paneles estan generando por debajo del rendimiento esperado, si la hora actual es cara o barata en el mercado spot, o si retrasar el arranque de un compresor 90 minutos supondria ahorrar varios cientos de euros al dia. La consecuencia es una programacion energetica suboptima, oportunidades de arbitraje de bateria desaprovechadas e incapacidad para validar el caso de negocio financiero de la inversion solar.

SunSaver aborda esto automatizando la cadena de suministro de datos completa: desde ficheros Excel de configuracion y respuestas de APIs externas, pasando por tablas Plata validadas, hasta una capa Gold de star schema completamente poblada que alimenta dashboards BI, sistemas de alertas y algoritmos de optimizacion.

Metrica Clave	Valor
Etapas del pipeline	6 (Bronce -> Plata -> Oro)
Fuentes de datos externas	3 (Excel, API REE, API OpenWeatherMap)
Modelos fisicos implementados	5 (Haurwitz, Erbs, Liu-Jordan, Faiman, Derating termico)
Tablas en la capa Gold	4 (3 dimensiones + 1 tabla de hechos)
Soporte multi-cliente	Instalaciones ilimitadas en una sola ejecucion
Modo de ejecucion	Desatendido, idempotente, reanudable desde cualquier etapa

2. El Problema Industrial

Una instalacion fotovoltaica en una planta industrial es un activo financiero que debe gestionarse activamente para entregar el ROI prometido. Sin embargo, la infraestructura de datos para hacerlo esta practicamente ausente en la mayoria de casos:

Sin visibilidad de generacion	El inversor produce kWh, pero estan aislados en un portal propietario sin API ni integracion con sistemas de negocio.
Sin programacion consciente del precio	El responsable de produccion arranca la linea de inyeccion a las 07:00 — el periodo mas caro (P1 Punta). Ningun sistema sugiere arrancarla a las 05:30 con solar + bateria.
Sin capacidad predictiva	Los cambios meteorologicos son invisibles para el sistema energetico. Una tarde nublada implica que la bateria no se precarga desde la red durante la tarifa nocturna barata.
Sin validacion del ROI	Financiero no puede verificar si el sistema FV genero lo prometido. No existe un registro historico auditable de generacion vs. consumo vs. precio.

SunSaver ETL elimina las cuatro brechas proporcionando un pipeline de datos unico y automatizado que consolida cada variable relevante en una base de datos estructurada y actualizada diariamente.

3. Arquitectura del Sistema

SunSaver implementa la Arquitectura Medallion, un patron de ingenieria de datos por capas que separa la ingesta bruta (Bronce), los datos validados (Plata) y las agregaciones listas para analisis (Oro). Esta separacion proporciona trazabilidad de auditoria completa, reprocesamiento seguro y superficies analiticas limpias.

3.1 Definicion de Capas

Bronce	Ingesta bruta, solo-append Los datos se escriben tal como se reciben, nunca se modifican. Cada fila lleva <code>_ingested_at_utc</code> . Tablas: <code>raw_clients</code> , <code>raw_prices</code> , <code>raw_weather</code> .
Plata	Validado, tipado, deduplicado Columnas convertidas a tipos correctos, nulos gestionados con defaults de ingenieria, coordenadas validadas, duplicados resueltos por recencia. Tablas: <code>clean_clients</code> , <code>clean_prices</code> , <code>clean_weather</code> , <code>clean_calculations</code> .
Oro	Star schema listo para analisis Tablas de hechos y dimensiones para BI y ML. Periodos tarifarios espanoles pre-calculados, flags booleanos derivados. Tablas: <code>gold_fact_energy_forecast</code> + 3 dimensiones.

3.2 Etapas de Ejecucion

Etapas	Paso	Funcion	Entrada -> Salida
1	1a	<code>extract_clients</code>	Excel -> <code>raw_clients</code>
1	1b	<code>extract_energy_prices</code>	API REE -> <code>raw_prices</code>
2	2a	<code>transform_clients</code>	<code>raw_clients</code> -> <code>clean_clients</code>
2	2b	<code>transform_energy_prices</code>	<code>raw_prices</code> -> <code>clean_prices</code>
3	3a	<code>extract_openweather</code>	API OpenWeather -> <code>raw_weather</code>
4	4a	<code>transform_openweather</code>	<code>raw_weather</code> -> <code>clean_weather</code>
5	5a	<code>extract_generation_data</code>	<code>clean_clients</code> + <code>clean_weather</code> -> <code>clean_calculations</code>
6	6a-6d	<code>gold_dim_*</code> + <code>gold_fact_*</code>	Silver -> star schema Gold

4. Motor de Fisica — pv_generation_engine.py

El motor de fisica es el diferenciador tecnico de SunSaver. Implementa una cadena validada de modelos fotovoltaicos y atmosfericos, cada uno operando sobre la salida del anterior. Este enfoque proporciona resultados fisicamente interpretables, fiables incluso para instalaciones nuevas sin datos historicos.

4.1 Cadena de Modelos

1. Posicion Solar

`pvlib.solarposition`

Calcula elevacion solar (a) y azimut para cualquier (lat, lon, UTC). Umbral de 2 grados protege contra inestabilidad numerica cerca del horizonte.

2. GHI Haurwitz

`GHI = 1098 * sin(a) * exp(-0.057 / sin(a))`

Estima la Irradiancia Global Horizontal en cielo despejado. Correccion por nubosidad (Kasten-Czeplak, relacion cubica) y factor por codigo meteorologico OpenWeather.

3. Descomposicion Erbs

`kt = GHI / (DNI_extra * sin(a))`

Descompone GHI en DNI (directa normal) y DHI (difusa horizontal) mediante correlaciones de Erbs. Validado con datos europeos.

4. POA Liu-Jordan

`POA = G_haz + G_difusa + G_albedo`

Transpone las componentes al plano inclinado del panel considerando inclinacion (angle), orientacion (aspect) y albedo estandar del suelo 0.2.

5. Temperatura Celula Faiman

`T_cel = T_amb + POA / (U0 + U1 * v_viento)`

Calcula temperatura de operacion de la celula con enfriamiento convectivo por viento. Coeficientes U0=24.9, U1=6.1 para bastidor abierto.

6. Potencia de Salida

`P_AC = (POA / 1000) * P_pico * PR`

Aplica derating termico gamma=-0.4%/°C sobre STC y perdidas fijas del sistema. Devuelve potencia kW y Performance Ratio.

7. Consumo Industrial

`Turno + HVAC + ruido_gaussiano`

Simula carga industrial realista: picos de arranque (95%), valle mediodia (60%), HVAC termico (+2%/°C>25°C), variabilidad gaussiana sigma=3%.

5. Modelo de Datos — Star Schema Gold

La capa Oro implementa un star schema optimizado para herramientas BI y consultas analiticas. La tabla de hechos central contiene una fila por cliente por intervalo de pronostico (3 horas), enlazando con tres tablas de dimension.

5.1 gold_fact_energy_forecast (Tabla de Hechos)

Columna	Tipo	Descripcion
client_id	TEXT PK	FK -> gold_dim_client
unix_time	INTEGER PK	FK -> gold_dim_datetime (segundos epoch)
forecast_time_utc	TEXT	Marca temporal del pronostico ISO 8601
pv_power_gen_kw	REAL	Generacion AC estimada (kW)
pv_performance_ratio	REAL	PR: rendimiento real vs. nominal
poa_wm2	REAL	Irradiancia en el plano del array (W/m2)
t_cell_celsius	REAL	Temperatura de operacion de celula (°C)
power_consumption_kw	REAL	Carga industrial simulada (kW)
temp_celsius	REAL	Temperatura ambiente (°C)
humidity_pct	REAL	Humedad relativa (%)
clouds_pct	REAL	Cobertura nubosa (0-100%)
rain_prob_norm	REAL	Probabilidad de precipitacion (0-1)
wind_speed_mps	REAL	Velocidad del viento (m/s)
weather_id	INTEGER	FK -> gold_dim_weather
price_pvpc_eur_mwh	REAL	Tarifa PVPC regulada (EUR/MWh)
price_spot_eur_mwh	REAL	Promedio horario Spot (EUR/MWh)
_loaded_at_utc	TEXT	Marca temporal de la ejecucion

5.2 Tablas de Dimension

gold_dim_datetime

Una fila por unix_time unico. Pre-calcula el periodo tarifario (P1 Punta / P2 Llano / P3 Valle / P6 Super-Valle) segun regulacion espanola 3.0TD. Flags: is_weekend, is_festivo, is_daylight. Marcas temporales UTC y hora local Europe/Madrid.

gold_dim_client

Una fila por instalacion. Todos los parametros fisicos mas dos flags booleanos derivados: has_solar y has_battery. Dimension de cambio lento — reconstruida en cada ejecucion desde el Excel maestro.

gold_dim_weather

Tabla de lookup de codigos meteorologicos OpenWeather. Cuando un weather_id tiene multiples descripciones, la mas frecuente gana mediante funcion de ventana SQL ROW_NUMBER() OVER PARTITION BY.

6. Referencia de Scripts

orchestrator.py	Punto de Entrada
Controla el pipeline completo de 6 etapas. Acepta --stage N para reanudar y --dry-run para previsualizar. Cada paso cronometrado con retorno True/False. Aborto automatico si toda una etapa critica falla.	
db_manager.py	Utilidad Compartida
Unico modulo que resuelve la ruta a sunsaver.db. Lee DB_PATH del .env o usa default. Garantiza que /data exista. Importado por todos los scripts que acceden a la BD.	
pv_generation_engine.py	Motor de Fisica
Cadena de 7 funciones: posicion solar -> GHI -> DNI/DHI -> POA -> T_celula -> P_AC -> P_consumo. Retorno seguro (0.0) ante excepciones para no interrumpir el ETL.	
extract_clients.py	Bronce — Etapa 1a
Lee clients_source.xlsx con pandas/openpyxl. Append a raw_clients con auditoria _ingested_at_utc. Capa Bronce es inmutable.	
extract_energy_prices.py	Bronce — Etapa 1b
Consulta API publica REE para precios PVPC + Spot del dia siguiente. Blob JSON a raw_prices. Gestiona error 502 (precios no publicados) de forma controlada.	
extract_openweather.py	Bronce — Etapa 3
Lee coordenadas de clean_clients, llama OpenWeatherMap Forecast por cliente. Aislamiento de errores por cliente: un fallo no aborta al resto.	
extract_power_data.py	Plata — Etapa 5
JOIN SQL de clean_clients + clean_weather, calculo fisico por fila via pv_generation_engine. UPSERT en clean_calculations con PK (client_id, unix_time).	
transform_clients.py	Plata — Etapa 2a
Coercion de tipos, validacion de coordenadas, recorte de rangos fisicos, guardias contra negativos, resolucion de duplicados por recencia, relleno de nulos con defaults de ingenieria.	
transform_energy_prices.py	Plata — Etapa 2b
Aplana JSON REE en filas PVPC + Spot. Filtrado outliers [-100,2000] EUR/MWh. Interpolacion lineal para huecos. UPSERT con PK (datetime_utc, price_type).	
transform_openweather.py	Plata — Etapa 4

Desempaqueta JSON OpenWeather por cliente, aplana 40 ventanas de pronostico. Deriva is_daylight del campo pod. UPSERT con PK (client_id, unix_time).

transform_gold_dim_clients.py**Oro — Etapa 6a**

Materializa gold_dim_client desde clean_clients. Deriva has_solar y has_battery. DROP + CREATE + INSERT atomicos en transaccion unica.

transform_gold_dim_datetime.py**Oro — Etapa 6b**

Dimension temporal desde unix_time de clean_weather. Periodos tarifarios 3.0TD, is_weekend, is_festivo, UTC y hora local Europe/Madrid.

transform_gold_dim_weather.py**Oro — Etapa 6c**

Lookup de codigos meteorologicos. Resuelve conflictos de descripcion por frecuencia usando ROW_NUMBER() OVER PARTITION BY.

transform_gold_fact_energy.py**Oro — Etapa 6d**

INSERT multi-JOIN ensamblando la tabla de hechos. Precios Spot promediados por hora antes del join. Indices sobre unix_time y weather_id.

7. Patrones de Ingenieria y Decisiones de Diseno

Patron UPSERT Idempotente

Todas las escrituras en Plata y Oro usan INSERT OR REPLACE con claves primarias compuestas. El pipeline puede ejecutarse multiples veces al dia sin crear duplicados. Bronce es la unica capa que hace append, preservando el rastro de auditoria completo.

Logica de Aborto por Etapas

El orquestador rastrea resultados por etapa. Si todos los pasos de una etapa devuelven False, la ejecucion se detiene con mensaje explicito. Evita que datos corruptos en Plata se propaguen silenciosamente a la capa Gold.

Aislamiento de Errores por Cliente

En `extract_openweather.py` y `extract_power_data.py`, cada cliente se procesa en un try/except independiente. El fallo de un cliente se registra y omite — el pipeline continua para el resto.

Guardia a 2 Grados de Elevacion Solar

Cerca del horizonte, los modelos de irradiancia basados en cosenos son numericamente inestables. SunSaver fuerza `elevacion < 2 grados` -> todos los valores = 0.0, eliminando picos de generacion fantasma.

Bronce como Log Inmutable

Las respuestas brutas nunca se modifican tras la ingesta. Proporciona cumplimiento regulatorio, capacidad de replay historico y superficie de depuracion cuando las transformaciones Plata producen resultados inesperados.

Autoridad Unica de Ruta a BD

`db_manager.py` es el unico modulo que calcula la ruta a la base de datos. Ningun script codifica rutas fijas. Resolucion correcta independientemente del directorio de invocacion, usando `__file__` como ancla.

8. Guia de Inicio Rapido

8.1 Requisitos Previos

Python: 3.11 o superior

Dependencias pip: pvlib, pandas, numpy, requests, sqlalchemy, python-dotenv, openpyxl (ver requirements.txt)

Clave API OpenWeatherMap: Nivel gratuito suficiente (~10 llamadas por ejecucion del pipeline)

API REE: Sin clave. Endpoint publico. Precios del dia siguiente disponibles desde ~20:30 CET.

8.2 Instalacion y Configuracion

```
git clone https://github.com/tu-usuario/sunsaver-etl.git cd sunsaver-etl pip install -r requirements.txt cp .env.example .env # Anadir WEATHER_API_KEY al fichero .env
```

8.3 Ejecucion del Pipeline

```
# Pipeline completo cd src python orchestrator.py # Reanudar desde Etapa 3 (p.ej., tras timeout de la API meteorologica) python orchestrator.py --stage 3 # Previsualizar plan sin ejecutar nada python orchestrator.py --dry-run # Programar diariamente con cron (21:00 CET) 0 21 * * * cd /ruta/sunsaver-etl/src && python orchestrator.py >> /ruta/logs/pipeline.log 2>&1
```

9. Valor de Negocio y Casos de Uso

Desplazamiento de Cargas

Correlacionando `pv_power_gen_kw` con `price_pvpc_eur_mwh` y `tariff_period`, los responsables de energia identifican horas con excedente solar y precios bajos — ventanas optimas para compresores, electrolizadores o camaras frigorificas. Ahorro potencial del 20-40% en coste de red.

Arbitraje de Bateria

La capa Gold proporciona todos los inputs para un optimizador de carga/descarga de bateria: generacion prevista, consumo esperado, precios PVPC y Spot, restricciones de SOC. Un sistema LP o basado en reglas puede reducir el coste energetico diario entre un 15 y un 35%.

Dashboards BI

El star schema conecta directamente a Power BI, Grafana o Superset. Metricas estandar: kWh diarios generados, % autoconsumo, valor de excedente vertido, tendencia del PR, coste tarifario por periodo.

Validacion del ROI

Audidores y financiero pueden comparar `gold_fact_energy_forecast` con lecturas reales del contador para verificar si el sistema FV cumple las garantias de rendimiento contractuales.

Feature Store para ML

La capa Gold es un feature store listo para modelos supervisados: prediccion de balance energetico neto, deteccion de anomalias en el performance ratio, prediccion probabilistica del consumo.

10. Stack Tecnologico

Capa	Libreria / Herramienta	Version	Rol
Modelado FV	pvlib	0.11+	Posicion solar, descomposicion de irradiancia (Erbs)
Datos	pandas	2.x	Operaciones DataFrame, ingesta Bronze
Matematica	numpy	1.26+	Calculos fisicos vectorizados
Base de datos	SQLite	3.x	Almacenamiento embebido sin configuracion
ORM / SQL	SQLAlchemy	2.x	UPSERT, DDL, gestion de transacciones

HTTP	requests	2.x	Llamadas a APIs REE y OpenWeatherMap
Configuracion	python-dotenv	1.x	Gestion de variables de entorno
Excel	openpyxl	3.x	Lectura del fichero de configuracion de clientes

SunSaver esta disenado para ser agnostico a la base de datos en la capa ORM. Migrar de SQLite a PostgreSQL requiere unicamente cambiar la cadena de conexion — todas las llamadas SQLAlchemy son compatibles con el dialecto PostgreSQL via psycopg2.